

# 科学计算与数学建模实验指导书

## 内 容 简 介

本课程以数学建模思想、方法为主线，有机融入科学计算的理论与方法，是集科学计算方法、现代数学、计算机技术与实际问题求解于一体的一门新型课程，采用研究性教学与探索型学习相结合的教学模式，主要讲授数学建模思想和科学计算方法。

本课程的学习应注重理论与实践相结合，因此实验教学是教学环节中必不可少的重要内容。在教学实验过程中，以实际问题为背景，渗透数学建模思想，通过课程中所学到数学建模的步骤和方法，编程实现实际问题的数学模型，用模型的求解引入科学计算的基本知识和一般方法。

实验部分包括实验目的、实验内容和实验所需环境等，介绍了每个实验所需的一些基础知识和技巧。在实验中给出的实验题，跟课堂教学的内容都有密切的关系，所以需要将课堂上讲授的例子程序融会贯通，掌握实验所需的一些基本方法和工具，并在吃透例子程序的基础上，积极独立思考设计和编写满足实验要求的程序。

# 上机实验要求及规范

深度学习课程具有比较强的实践性。上机实验是一个重要的教学环节。一般情况下学生能够重视实验环节，对于编写程序上机练习具有一定的积极性。但是容易忽略实验的总结，忽略实验报告的撰写。对于一名大学生必须严格训练分析总结能力、书面表达能力。需要逐步培养书写科学实验报告以及科技论文的能力。拿到一个题目，一般不要急于编程。正确的方法是：首先理解问题，明确给定的条件和要求解决的问题，然后按照自顶向下，逐步求精，分而治之的策略，按照面向对象的程序设计思路，逐一地解决子问题。

## 一、实验报告的基本要求：

一般性、较小规模的上机实验题，必须遵循下列要求。养成良好的习惯。

姓名 班级 学号 日期 题目

- i. 问题描述
- ii. 设计简要描述
- iii. 程序清单（带有必要的注释）
- iv. 结果分析（原始图示，测试数据与运行记录，分析正确性；）
- v. 调试报告：

实验者必须重视最后这两个环节，否则等同于没有完成实验任务。这里可以体现个人特色、或创造性思维。具体内容包括：测试数据与运行记录；调试中遇到的主要问题，自己是如何解决的；经验和体会等。

## 二、实验报告的提高要求：

阶段性、较大规模的上机实验题，应该遵循下列要求。养成科学的习惯。

- (1) 问题描述
- (2) 需求和规格说明
- (3) 描述问题，简述题目要解决的问题是什么。规定软件做什么。原题条件不足时补全。
- (4) 概要设计：功能模块的划分
- (5) 详细设计：每部分模块的设计，含数据结构的设计，算法的描述（流程图或PDL）
  - a. 设计思想：主要算法基本思想。
  - b. 设计表示：每个函数的头和规格说明；列出每个函数所调用和被调用的函数，也可以通过调用关系图表达。
- (6) 实现注释：各项功能的实现程度、在完成基本要求的基础上还有什么功能。
- (7) 用户手册：即使用说明书。
- (8) 调试报告：调试过程中遇到的主要问题是如何解决的；设计的回顾、讨论和分析；时间复杂度、空间复杂度分析；改进设想；经验和体会等。

# 基于深度学习的医药诊断评估系统

## 一、实验目的

- ① 掌握卷积网络、嵌入层、LSTM、自编码器等方面的内容
- ② 学会搭建 Python 开发环境
- ③ 学会使用 PyTorch 和 Keras 框架搭建神经网络
- ④ 学会使用 pyplot 绘制实验结果

## 二、实验开发环境和工具

可以在Linux、Windows或Mac操作系统上搭建开发环境，所使用的开发工具包括Anaconda、PyTorch、Tensorflow、Keras等，使用Python语言。因为Keras是基于Tensorflow的高层API,所以需要先安装Tensorflow再安装Keras。

实验指导书中的内容以在Windows系统下使用PyCharm进行开发为例。

## 三、实验内容

本次实验需要完成医药诊断系统中的两个模块：基于自编码器和卷积网络的肺炎图像识别模块和基于嵌入层和LSTM的药物评价情感分析模块。

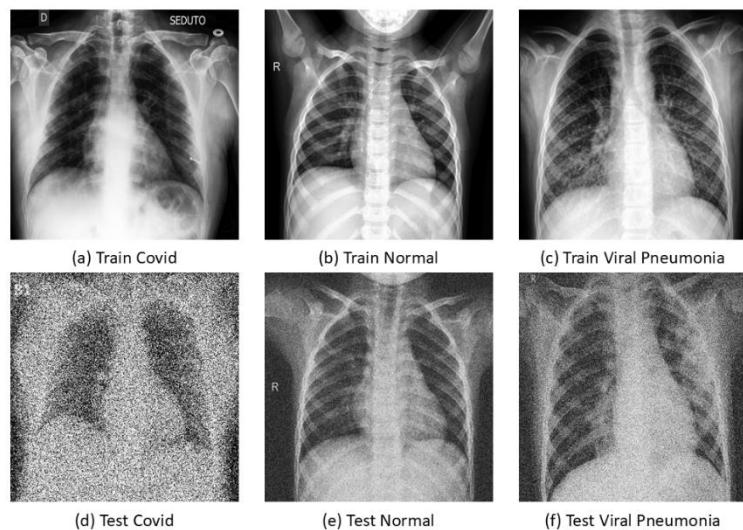
### 1. 基于自编码器和卷积网络的肺炎图像识别模块

#### 1.1 数据介绍

实验使用肺部X-光片作为数据集，标签分为三类：新冠肺炎、正常和普通肺炎。数据分布如下表所示：

|       | Covid | Normal | Viral Pneumonia |
|-------|-------|--------|-----------------|
| Train | 111   | 70     | 70              |
| Test  | 26    | 20     | 20              |

对于测试集的图片，我们使用高斯噪声进行了扰动。对于训练集，我们使用原始的干净图片。



## 1.2 实验准备

实验开始前，需要先安装PyTorch，可以通过命令行的方式安装CPU版本：

```
>pip3 install torch torchvision torchaudio
```

或

```
>conda install pytorch torchvision torchaudio cpoonly -c pytorch
```

更推荐安装GPU版本并使用显卡进行训练。安装GPU版本前需要先安装CUDA，可以参考[CSDN](#)的教程。安装完CUDA后可以在[PyTorch](#)上找到对应CUDA版本PyTorch的安装命令。

## 1.3 实验步骤

### 1.3.1 导入相关库

```
import matplotlib.pyplot as plt
import torch
import torch.nn as nn
import torch.nn.functional as F
from torch.utils.data import DataLoader
from torchvision import transforms, datasets
from tqdm import tqdm
```

plt用于绘图，nn中包含了用于构建神经网络的隐藏层（全连接层、卷积层等），F中包含了各种激活函数（ReLU、Sigmoid等），DataLoader用于在训练时加载数据，datasets和transforms用于读取和处理数据集，tqdm用于进度条可视化。

### 1.3.2 定义超参数

```
TRAIN_BATCH_SIZE = 32
TEST_BATCH_SIZE = 66
EPOCHS = 50
LR = 0.01
device = "cuda" if torch.cuda.is_available() else "cpu"
print('[INFO] Running on ' + device)
```

TRAIN\_BATCH\_SIZE：训练时批次大小，即一次更新使用多少样本进行梯度计算。设置的越大，占用显存越多，但计算次数越少。一般设置为2的n次方。

TEST\_BATCH\_SIZE：与上类似，此处66为测试集总样本数，即一次性将所有测试数据放入模型计算。

EPOCHS：总共训练多少轮。每一轮训练会遍历一遍训练数据。

LR：学习率，也叫做步长， $w_{t+1} = w_t - \eta g$ 中的 $\eta$ 。

device：使用何种设备进行训练，如果安装的cpu版本则只能使用cpu。

### 1.3.3 读取数据

torch对于一些常用的数据集做了封装，可以直接调用，例如datasets.MNIST()。但此处我们使用的是本地的图片数据，可以使用ImageFolder将一个文件夹下的图片读取成数据集。

```

train_dataset = datasets.ImageFolder('../data/covid19/train',
                                    transforms.Compose([
                                        transforms.Grayscale(),
                                        transforms.Resize((256, 256)),
                                        transforms.ToTensor()])
)

```

`transforms`指在读取数据时对数据进行的处理。

`Grayscale`: 指以灰度图的形式读取。

`Resize`: 由于图片文件尺寸不一致，在训练前需要将它们重塑成相同尺寸。

`ToTensor`: 将图片格式转换成张量形式，`torch`的计算以张量的形式进行。

常用的还有`Normalize`进行标准化等。

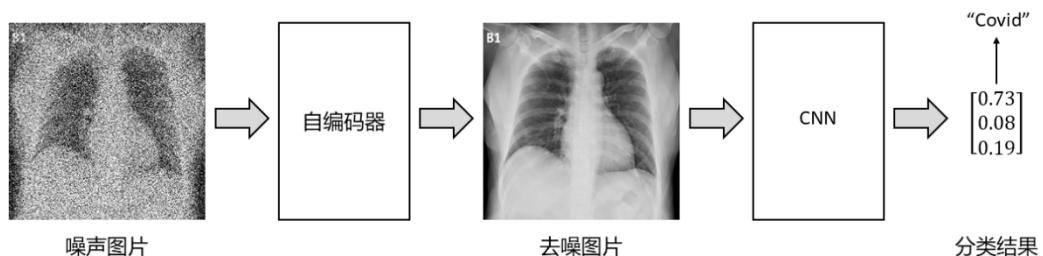
在读取完数据集后还需要定义`DataLoader`用于加载数据。

```
train_dataloader = DataLoader(train_dataset, batch_size=TRAIN_BATCH_SIZE, shuffle=True)
```

对于测试集的处理类似，请同学们自行完成。

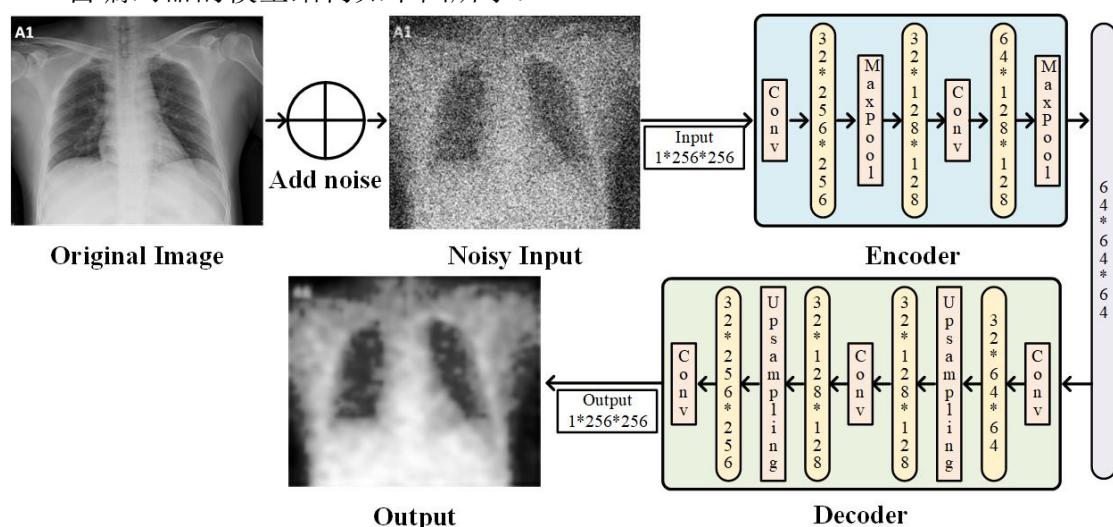
#### 1.3.4 定义模型

本模块由两个模型组成，分别是用于去噪的自编码器和用于分类的CNN。



##### (1) 自编码器

自编码器的模型结构如下图所示：



模型定义代码如下：

```
class Autoencoder(nn.Module):
    def __init__(self):
        super(Autoencoder, self).__init__()
        self.encoder = nn.Sequential(
            nn.Conv2d(1, 32, kernel_size=3, stride=1, padding=1),
            nn.ReLU(),
            nn.MaxPool2d(2, stride=2),
            nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1),
            nn.ReLU(),
            nn.MaxPool2d(2, stride=2)
        )
        self.decoder = nn.Sequential(
            nn.Conv2d(64, 32, kernel_size=3, stride=1, padding=1),
            nn.ReLU(),
            nn.UpsamplingNearest2d(scale_factor=2),
            nn.Conv2d(32, 32, kernel_size=3, stride=1, padding=1),
            nn.ReLU(),
            nn.UpsamplingNearest2d(scale_factor=2),
            nn.Conv2d(32, 1, kernel_size=3, stride=1, padding=1),
            nn.Sigmoid()
        )

    def forward(self, x):
        x = self.encoder(x)
        x = self.decoder(x)
        return x
```

模型继承自nn.Module类，在\_\_init\_\_()函数中定义模型的结构，在forward()函数中定义模型的前向传播过程。

## (2) CNN

以下分别是CNN的模型结构和前向传播过程：

```
self.conv1 = nn.Conv2d(in_channels=1, out_channels=16, kernel_size=3, stride=1, padding=1)
self.conv2 = nn.Conv2d(in_channels=16, out_channels=32, kernel_size=3, stride=1, padding=1)
self.pool = nn.MaxPool2d(kernel_size=2, stride=2, padding=0)
self.fc1 = nn.Linear(in_features=32 * 64 * 64, out_features=128)
self.fc2 = nn.Linear(in_features=128, out_features=32)
self.fc3 = nn.Linear(in_features=32, out_features=3)

def forward(self, x):
    x = self.pool(F.relu(self.conv1(x)))
    x = self.pool(F.relu(self.conv2(x)))
    x = x.view(-1, 32 * 64 * 64)
    x = F.relu(self.fc1(x))
    x = F.relu(self.fc2(x))
    x = self.fc3(x)
    return x
```

请同学们仿照自编码器结构图绘制出CNN的网络结构图，包括数据经过每一个隐藏层后的尺寸变化（不必绘制激活函数）。

### 1. 3. 5 模型训练

#### (1) 初始化模型

```
autoencoder = Autoencoder().to(device)
```

通过to()来指定在CPU或GPU上计算。

#### (2) 指定损失函数与优化器算法

```
criterion = nn.MSELoss()  
optimizer = torch.optim.Adam(autoencoder.parameters(), lr=LR)
```

自编码器选用均方差作为损失函数，Adam作为优化器。

#### (3) 开始训练

基本的训练流程如下所示：

```
autoencoder.train()  
for epoch in range(EPOCHS):  
    for img, label in tqdm(train_dataloader):  
        img = img.to(device)  
        noisy_img = add_noise(img)  
        optimizer.zero_grad()  
        reconstructed = autoencoder(noisy_img)  
        loss = criterion(reconstructed, img)  
        loss.backward()  
        optimizer.step()
```

每次更新执行如下操作：

- ① 从加载器中获取输入数据
- ② 清空梯度
- ③ 计算模型输出
- ④ 根据模型输出和标签计算loss
- ⑤ 反向传播
- ⑥ 更新模型

由于训练集是干净图片，我们在将其输入到模型之前需要手动添加噪声，代码如下：

```
def add_noise(img, noise_factor=0.5):  
    noisy_img = img + noise_factor * torch.randn_like(img)  
    noisy_img = torch.clamp(noisy_img, 0., 1.)  
    return noisy_img
```

请同学们自行完成：在训练过程中打印每个epoch的平均loss变化情况，如下图所示：

```
100%|██████████| 8/8 [00:05<00:00, 1.53it/s]
[Autoencoder] Epoch 45/50 Loss: 0.0044
100%|██████████| 8/8 [00:05<00:00, 1.55it/s]
[Autoencoder] Epoch 46/50 Loss: 0.0043
100%|██████████| 8/8 [00:05<00:00, 1.53it/s]
[Autoencoder] Epoch 47/50 Loss: 0.0043
100%|██████████| 8/8 [00:04<00:00, 1.61it/s]
[Autoencoder] Epoch 48/50 Loss: 0.0043
100%|██████████| 8/8 [00:05<00:00, 1.57it/s]
[Autoencoder] Epoch 49/50 Loss: 0.0043
100%|██████████| 8/8 [00:04<00:00, 1.61it/s]
[Autoencoder] Epoch 50/50 Loss: 0.0043
```

提示：loss变量的类型是Tensor，通过loss.item()可以获取其值。

对于CNN，损失函数选用交叉熵，训练过程与上类似，需要注意的是，在将数据输入模型前，除了需要手动添加噪声，还需要先通过autoencoder，为了不在更新CNN的同时更新自编码器，这一步不需要产生梯度：

```
for data, label in train_dataloader:
    data, label = data.to(device), label.to(device)
    noisy_data = add_noise(data)
    with torch.no_grad():
        input = autoencoder(noisy_data)
    output = model(input)
```

请同学们自行完成CNN的训练，并打印训练过程中loss和正确率的变化。

提示：下述代码可以计算出当前批次中被正确判断的样本数：

```
pred = output.argmax(
    dim=1, keepdim=True
)
correct += pred.eq(target.view_as(pred)).sum().item()
```

模型的保存与加载：

```
torch.save(model.state_dict(), '../model/cnn.pth')

model.load_state_dict(torch.load('../model/cnn.pth', weights_only=True))
```

### 1.3.6 模型测试

可以在每个epoch结束时对模型进行测试，测试代码与训练代码类似，只是不会进行更新，代码如下：

```
model.eval()
with torch.no_grad():
    for data, label in test_dataloader:
        data, label = data.to(device), label.to(device)
        data = autoencoder(data)
        output = model(data)
        # 计算测试loss
        # 计算测试正确率
```

由于测试集已经是加噪的图片，我们不必手动添加噪声。

请同学们自行完成：打印CNN在不同epoch训练和测试的loss及正确率，如下图所示：

```
100%|██████████| 8/8 [00:04<00:00, 1.88it/s]
[CNN] Epoch 46/50 Train Loss: 0.000020 Accuracy: 100.00
[CNN] Epoch 46/50 Test Loss: 1.013535 Accuracy: 87.88
100%|██████████| 8/8 [00:04<00:00, 1.90it/s]
[CNN] Epoch 47/50 Train Loss: 0.000015 Accuracy: 100.00
[CNN] Epoch 47/50 Test Loss: 1.017201 Accuracy: 87.88
100%|██████████| 8/8 [00:04<00:00, 1.87it/s]
[CNN] Epoch 48/50 Train Loss: 0.000030 Accuracy: 100.00
[CNN] Epoch 48/50 Test Loss: 1.021951 Accuracy: 87.88
100%|██████████| 8/8 [00:04<00:00, 1.87it/s]
[CNN] Epoch 49/50 Train Loss: 0.000019 Accuracy: 100.00
[CNN] Epoch 49/50 Test Loss: 1.025834 Accuracy: 87.88
100%|██████████| 8/8 [00:04<00:00, 1.88it/s]
[CNN] Epoch 50/50 Train Loss: 0.000016 Accuracy: 100.00
[CNN] Epoch 50/50 Test Loss: 1.028288 Accuracy: 87.88
```

提示：可以把训练和测试的过程封装成函数train(epoch)和test(epoch)，在函数的最后打印对应信息，然后通过下方代码来执行训练和测试。

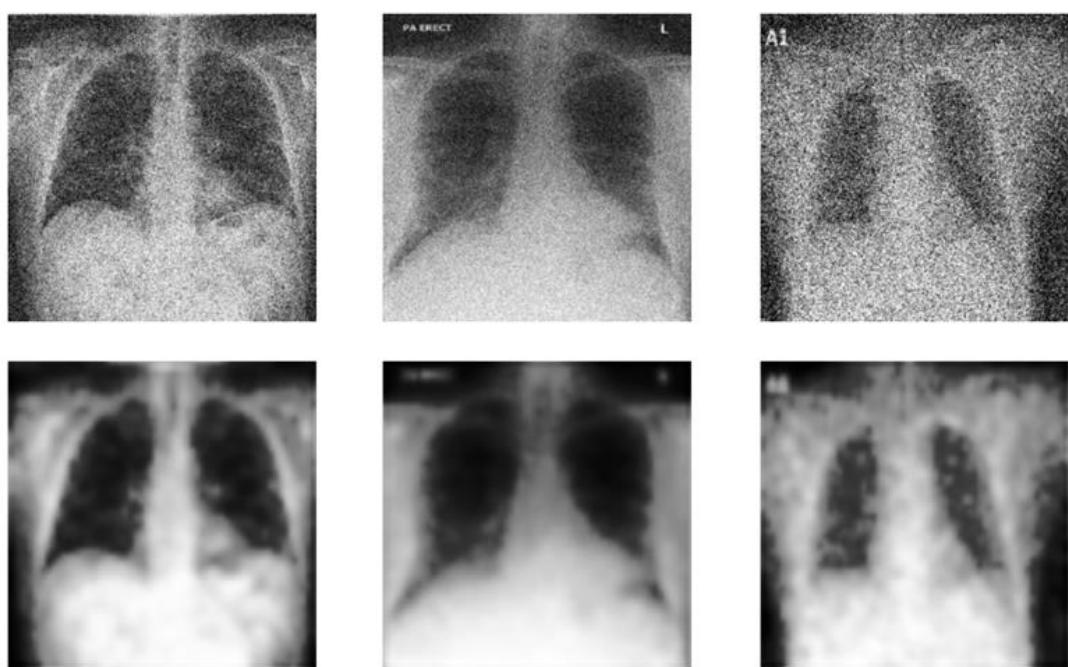
```
for i in range(EPOCHS):
    train(i)
    test(i)
```

### 1. 3. 7 绘制结果

#### (1) 自编码器结果绘制

我们在模型计算时使用的变量类型都是Tensor，我们需要先将其转换成图片形式，可以通过如下代码展示autoencoder的输入和输出。

```
for data, _ in test_dataloader:
    data = data.to(device)
    output = autoencoder(data)
    tp = transforms.ToPILImage()
    noisy_img = tp(data[0].cpu())
    reconstructed = tp(output[0].cpu())
    plt.imshow(noisy_img, cmap='gray')
    plt.axis('off')
    plt.show()
    plt.imshow(reconstructed, cmap='gray')
    plt.axis('off')
    plt.show()
```



(2) CNN训练过程正确率及loss可视化

可以定义两个列表用于存储训练过程中每个epoch的loss和正确率。

```
loss_per_epoch = []
acc_per_epoch = []
```

在训练和测试过程中，我们可以向这两个列表添加数据：

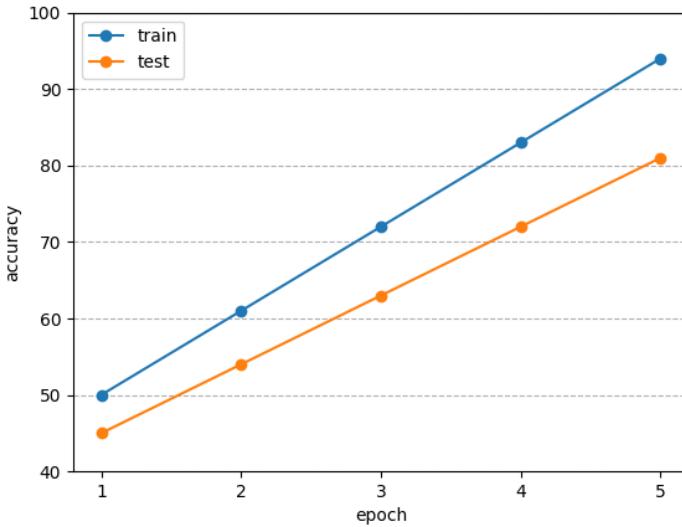
```
# 训练过程
# 计算loss
# 计算acc
loss_per_epoch.append(loss)
acc_per_epoch.append(acc)
```

有了数据之后，我们可以绘制正确率和loss的变化情况，下面是绘制折线图的代码示例（并非真实数据）：

```
import matplotlib.pyplot as plt
from matplotlib.pyplot import MultipleLocator

epoch = [1, 2, 3, 4, 5]
acc_train = [50, 61, 72, 83, 94]
acc_test = [45, 54, 63, 72, 81]

plt.plot(epoch, acc_train, label='train', marker='o')
plt.plot(epoch, acc_test, label='test', marker='o')
plt.xlabel('epoch')
plt.ylabel('accuracy')
plt.legend()
# y轴设置范围为40~100
plt.ylim(40, 100)
# x轴刻度设为1的倍数
ax = plt.gca()
ax.xaxis.set_major_locator(MultipleLocator(1))
# 背景绘制虚线
plt.grid(axis="y", linestyle='--')
plt.show()
```



### 1. 3. 8 (选做) 部署模型

把模型部署到实际应用中，以Web或GUI为用户提供操作接口以上传图片。Web可以考虑使用Flask作为服务端，GUI可以考虑使用PyQT开发。

## 2. 基于嵌入层和LSTM的药物评价情感分析模块

### 2. 1 数据介绍

本实验使用的数据集是国外对药物的评论及评分数据，数据集的属性如下表所示：

| uniqueID  | drugName | condition | review           | rating           | date     | usefulCount        |
|-----------|----------|-----------|------------------|------------------|----------|--------------------|
| 唯一<br>标识符 | 药物名称     | 病人<br>症状  | 病人对<br>药物的<br>评论 | 病人对<br>药物的<br>评分 | 评价<br>日期 | 觉得此评<br>价有用<br>的人数 |

评分取值为1到10的整数，在实验中我们只使用到review和rating属性。

### 2. 2 实验准备

在实验开始前，需要安装Tensorflow和Keras包，可以通过如下指令安装：

```
>pip install tensorflow
```

```
>pip install keras
```

提示：tensorflow和keras对numpy、pandas等包有着较为严格的版本依赖，如果担心破坏已有的python环境，建议创建一个新的环境。

### 2. 3 实验步骤

#### 2. 3. 1 导入相关包

```

import pandas as pd
from keras._tf_keras.keras.utils import to_categorical
from keras._tf_keras.keras.utils import pad_sequences
from keras._tf_keras.keras.preprocessing.text import Tokenizer
from keras._tf_keras.keras.models import Sequential
from keras._tf_keras.keras.layers import Embedding, Dense, LSTM
import matplotlib.pyplot as plt

```

pd用于读取csv格式的文件，to\_categorical、pad\_sequences和Tokenizer用于处理文本数据，Sequential、Embedding、Dense和LSTM用于搭建模型，plt用于绘图。

### 2.3.2 读取数据

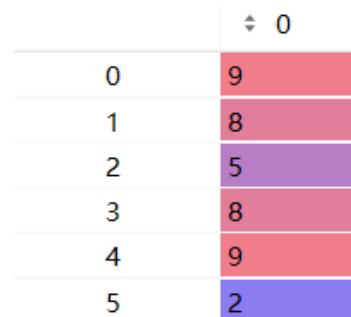
#### (1) 读取原始数据

```
train_data = pd.read_csv('../data/review/drugsComTrain_raw.csv')
```

|    | uniqueID | drugName              | condition           | review            | rating | date      | usefulCount |
|----|----------|-----------------------|---------------------|-------------------|--------|-----------|-------------|
| 0  | 206461   | Valsartan             | Left Ventricular... | "It has no si...  | 9      | 20-May-12 | 27          |
| 1  | 95260    | Guanfacine            | ADHD                | "My son is h...   | 8      | 27-Apr-10 | 192         |
| 2  | 92703    | Lybrel                | Birth Control       | "I used to ta...  | 5      | 14-Dec-09 | 17          |
| 3  | 138000   | Ortho Evra            | Birth Control       | "This is my fi... | 8      | 3-Nov-15  | 10          |
| 4  | 35696    | Buprenorphine / ...   | Opiate Depend...    | "Suboxone ...     | 9      | 27-Nov-16 | 37          |
| 5  | 155963   | Cialis                | Benign Prostati...  | "2nd day on...    | 2      | 28-Nov-15 | 43          |
| 6  | 165907   | Levonorgestrel        | Emergency Con...    | "He pulled ...    | 1      | 7-Mar-17  | 5           |
| 7  | 102654   | Aripiprazole          | Bipolar Disorde     | "Ability chan...  | 10     | 14-Mar-15 | 32          |
| 8  | 74811    | Kepra                 | Epilepsy            | " I Ve had n...   | 1      | 9-Aug-16  | 11          |
| 9  | 48928    | Ethinyl estradiol ... | Birth Control       | "I had been ...   | 8      | 8-Dec-16  | 1           |
| 10 | 29607    | Topiramate            | Migraine Preve...   | "I have been...   | 9      | 1-Jan-15  | 19          |

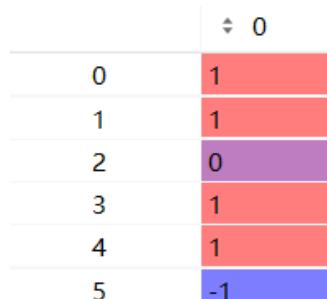
#### (2) 提取“评分”一列

```
train_rating = train_data['rating']
```



#### (3) 根据评分确定情感标签：1-4分：消极、5-6分：中性、7-10分：积极

```
train_label = -1 * (train_rating <= 4) + 1 * (train_rating >= 7)
```



测试集处理类似，自行完成。

### 2.3.3 处理数据

#### (1) 提取“评论”一列

|   | train_review = train_data['review']                                   |
|---|---|
| 0 | ↓ 0<br>"It has no side effect, I take it in combination of Bystolic.. |
| 1 | "My son is halfway through his fourth week of Intuniv. ...            |
| 2 | "I used to take another oral contraceptive, which had 2...            |
| 3 | "This is my first time using any form of birth control. I&...         |
| 4 | "Suboxone has completely turned my life around. I fee..               |
| 5 | "2nd day on 5mg started to work with rock hard erecti...              |

#### (2) 将文本序列化

```
tokenizer = Tokenizer(num_words=WORDS)
tokenizer.fit_on_texts(train_review)
train_sequence = tokenizer.texts_to_sequences(train_review)

▼ train_sequence = {list: 161297}
  > 000000 = {list: 17} [5, 38, 28, 35, 197, 1, 45, 5, 15, 848, 12, 2922, 99, 150, 2, 3806, 1551]
  > 000001 = {list: 141} [6, 638, 19, 3380, 225, 508, 1652, 76, 12, 3254, 262, 404, 1226, 62,
  > 000002 = {list: 138} [1, 153, 4, 45, 277, 1184, 1840, 90, 18, 912, 70, 542, 2, 10, 57, 266,
  > 000003 = {list: 93} [14, 19, 6, 44, 58, 182, 100, 729, 12, 140, 118, 1, 8, 34, 594, 1, 108, 21,
  > 000004 = {list: 127} [899, 38, 273, 788, 6, 92, 224, 1, 65, 2318, 1, 8, 34, 26, 6, 452, 2, 1,
  > 000005 = {list: 69} [625, 29, 13, 523, 49, 4, 113, 21, 2544, 368, 2248, 200, 346, 436, 720,
```

训练样本一共由161297句话，第一句话有17个单词，train\_sequence[i][j]中的值代表第i句话中第j个单词在字典中的下标。

#### (3) 将序列化后的文本填充并形成等长序列

```
x_train = pad_sequences(train_sequence, maxlen=LENGTH)
```

|   | ↓ 481 | ↓ 482 | ↓ 483 | ↓ 484 | ↓ 485 | ↓ 486 | ↓ 487 | ↓ 488 | ↓ 489 | ↓ 490 | ↓ 491 |
|---|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| 0 | 0     | 0     | 5     | 38    | 28    | 35    | 197   | 1     | 45    | 5     | 15    |
| 1 | 508   | 1951  | 19    | 107   | 73    | 262   | 11    | 134   | 221   | 248   | 417   |
| 2 | 1     | 121   | 8     | 22    | 11    | 100   | 115   | 35    | 43    | 3     | 973   |
| 3 | 12    | 6     | 80    | 1     | 105   | 18    | 184   | 83    | 182   | 140   | 118   |
| 4 | 19    | 32    | 5     | 9     | 17    | 5     | 785   | 19    | 383   | 3     | 650   |
| 5 | 60    | 4931  | 9     | 48    | 1693  | 1     | 8     | 34    | 480   | 166   | 113   |

#### (4) 将标签形成独热编码

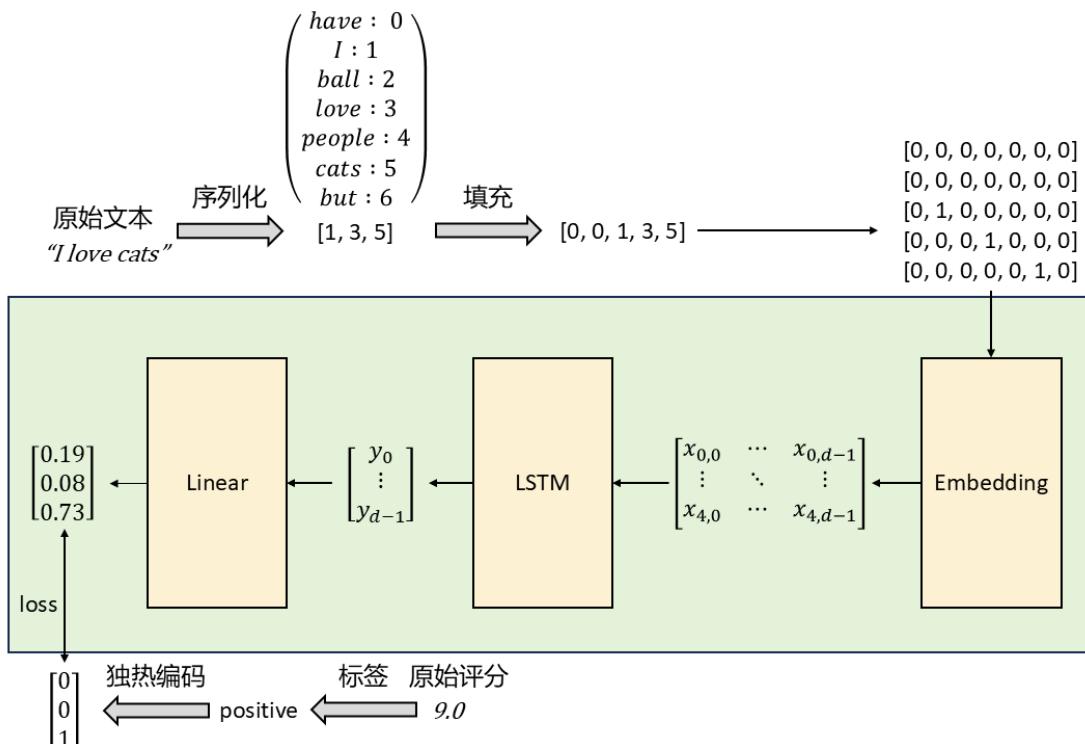
```
y_train = to_categorical(train_label, num_classes=3)
```

|   | 0       | 1       | 2       |
|---|---------|---------|---------|
| 0 | 0.00000 | 1.00000 | 0.00000 |
| 1 | 0.00000 | 1.00000 | 0.00000 |
| 2 | 1.00000 | 0.00000 | 0.00000 |
| 3 | 0.00000 | 1.00000 | 0.00000 |
| 4 | 0.00000 | 1.00000 | 0.00000 |
| 5 | 0.00000 | 0.00000 | 1.00000 |

对于测试集采用同样的处理方式，注意不需要一个新的tokenizer，如果专门再为测试集构建一个tokenizer相当于泄露了测试集的信息。

### 2.3.4 搭建模型

模型结构如下所示：



通过下述代码定义模型结构以及优化器、损失函数和性能指标：

```
model = Sequential()
model.add(Embedding(WORDS, DEPTH, input_length=LENGTH))
model.add(LSTM(DEPTH))
model.add(Dense(3, activation='softmax'))

model.compile(optimizer='rmsprop', loss='categorical_crossentropy', metrics=['acc'])
```

### 2.3.5 训练及评估模型

通过下述代码进行训练和测试：

```
history = model.fit(x_train, y_train, epochs=10, batch_size=32, verbose=1, validation_split=0.25)

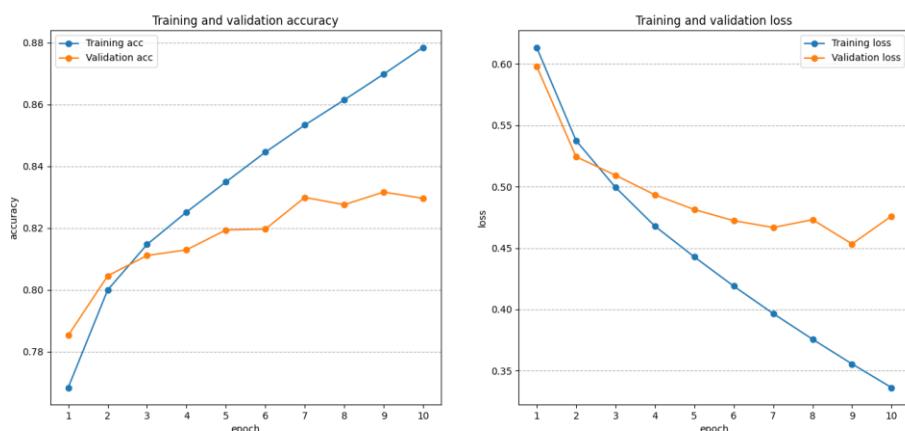
test_loss, test_acc = model.evaluate(x_test, y_test, verbose=1)
```

定义一个函数来绘制训练过程中的指标变化：

```

def plot_history(history):
    f, ax = plt.subplots(1, 2, figsize=(16, 7))
    acc = history.history['acc']
    val_acc = history.history['val_acc']
    loss = history.history['loss']
    val_loss = history.history['val_loss']
    epochs = range(1, len(acc) + 1)
    plt.sca(ax[0])
    ax[0].xaxis.set_major_locator(MultipleLocator(1))
    plt.plot(epochs, acc, marker='o', label='Training acc')
    plt.plot(epochs, val_acc, marker='o', label='Validation acc')
    plt.ylabel('accuracy')
    plt.xlabel('epoch')
    plt.title('Training and validation accuracy')
    plt.grid(axis="y", linestyle='--')
    plt.legend()
    plt.sca(ax[1])
    ax[1].xaxis.set_major_locator(MultipleLocator(1))
    plt.plot(epochs, loss, marker='o', label='Training loss')
    plt.plot(epochs, val_loss, marker='o', label='Validation loss')
    plt.ylabel('loss')
    plt.xlabel('epoch')
    plt.title('Training and validation loss')
    plt.grid(axis="y", linestyle='--')
    plt.legend()
    plt.show()

```



### 2.3.6 比较keras和torch两个框架各自的特点

### 2.3.7 (选做) 用torch复现本模块